# Математические методы анализа текстов
# Задачи разметки, условные случайные поля (CRF)

К. В. Воронцов, М. А. Апишев, А. С. Попов

Этот курс доступен на странице вики-ресурса
http://www.MachineLearning.ru/wiki
«Математические методы анализа текстов
(курс лекций) / осень 2019»

15 сентября 2020

# Содержание

# Примеры задач разметки и сегментации

- распознавание частей речи (part of speech tagging, POS)
- неглубокий синтаксический разбор (shallow syntax parsing)
- распознавание именованных сущностей (named entity, NER)
- выделение семантических ролей (semantic role labeling)
- анализ тональности заданной сущности (sentiment analysis)
- выделение текстовых полей данных (slot filling)
- выделение полей в библиографических записях
- сегментация научных или юридических текстов
- поиск кореференций и разрешение анафор
- поиск и разрешение эллипсиса (гэппинга)
- перевод речевого сигнала в текст
- перевод музыкального сигнала в нотную запись
- выделение генов в нуклеотидных последовательностях

# Пример частеречной и синтаксической разметки

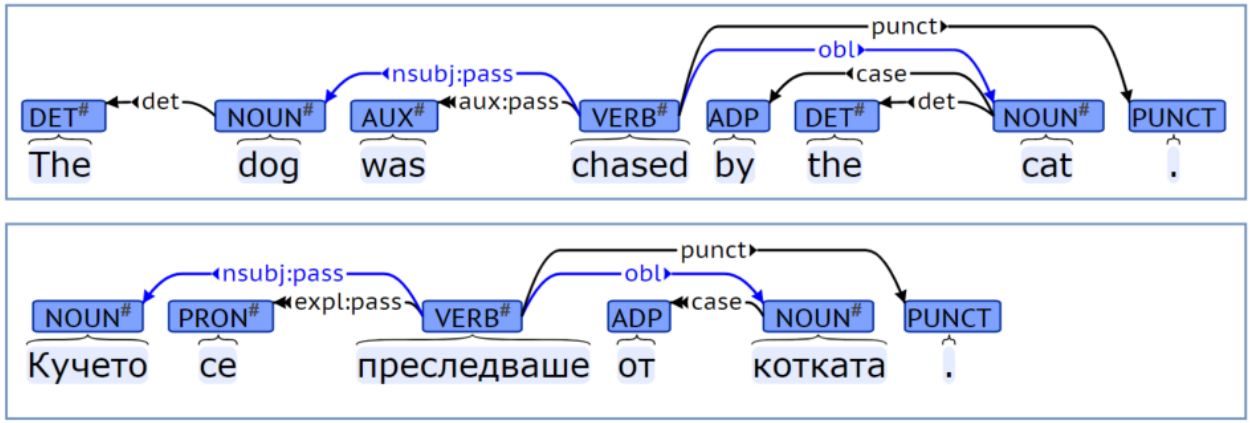


Теги частей речи (не все, и могут зависеть от языка):

| | | | | | |
|---|---|---|---|---|---|
| NOUN | noun | существительное | INTJ | interjection | междометие |
| PROPN | proper noun | имя собственное | ADP | adposition | предлог |
| ADJ | adjective | прилагательное | CONJ | conjunction | союз |
| VERB | verb | глагол | PART | particle | частица |
| ADV | adverb | наречие | PUNCT | punctuation | знак пунктуации |
| PRON | pronoun | местоимение | SYM | symbol | символ |
| NUM | numeral | числительное | X | other | иное |

http://universaldependencies.org/

# Пример выделения частей речи русского языка методом CRF

| Часть речи | Отн. частота ЧР, % | Точность, % | Полнота, % | F1, % |
|---|---|---|---|---|
| Существительное | 30.42 | 96.03 | 96.98 | 96.50 |
| Прилагательное | 9.40 | 92.45 | 92.16 | 92.30 |
| Глагол | 9.12 | 98.32 | 98.86 | 98.59 |
| Причастие | 0.76 | 82.37 | 82.58 | 82.48 |
| Деепричастие | 0.24 | 94.80 | 90.11 | 92.40 |
| Наречие | 4.17 | 96.43 | 96.07 | 96.25 |
| Предлог | 9.83 | 99.39 | 99.61 | 99.50 |
| Союз | 5.92 | 99.40 | 99.54 | 99.47 |
| Числительное (как слово) | 0.64 | 90.27 | 89.22 | 89.74 |
| Числительное (как цифра) | 1.56 | 92.80 | 94.78 | 93.78 |
| Личное местоимение | 1.20 | 99.31 | 99.84 | 99.57 |
| Другие местоимения | 3.65 | 98.89 | 98.68 | 98.78 |
| Сокращение | 0.35 | 96.69 | 82.23 | 88.88 |
| Знак препинания | 17.54 | 99.97 | 99.88 | 99.93 |
| Остальное | 4.66 | 84.68 | 79.35 | 81.93 |

*А. Ю. Антонова, А. Н. Соловьев.* Метод условных случайных полей в задачах обработки русскоязычных текстов. Диалог, 2013

# Разметка библиографических записей

Основные поля метаданных:

- автор(ы), название, издание, журнал, конференция,
- редактор, издательство, страна, город,
- страницы, номер, том, год, месяц,
- сайт, DOI, аннотация, ...

Проблема вариативности библиографических записей:

- David Blei, Andrew Ng, Michael Jordan. Latent Dirichlet allocation. JMLR, 2003.
- D.Blei, A.Ng, M.Jordan. Latent Dirichlet allocation // Journal of Machine Learning Research. 2003. V.3. Pp.993–1022.
- Blei, David M. and Ng, Andrew Y. and Jordan, Michael I. (2003). Latent Dirichlet allocation. Journal of Machine Learning Research. JMLR.org. Vol.3, P.993–1022.

# Разметка именованных сущностей (Named Entity Recognition)

Сущность всегда имеет категорию. Множество употребляемых категорий зависит от предметной области и жанра текста

- персона, организация, локация, дата-время
- профессия, должность, звание
- ссылка на нормативно-правовой акт
- артикул, изделие, производственный процесс
- заболевание, симптом, метод лечения,
- лекарственный препарат, химическое вещество
- биологический вид
- астрономический объект

---

Stanford Named Entity Recognizer:
`http://www-nlp.stanford.edu/software/CRF-NER.shtml`

# Разметка семантических ролей (semantic role labeling)

Задача — найти в предложении *актанты* — именные группы, обозначающие участников ситуации и их *семантические роли*

- агенс: одушевлённый инициатор и контролёр действия
- пациенс: участник, на которого направлено действие
- бенефактив: участник, получающий пользу или вред
- адресат: получатель сообщения (может быть бенефактивом)
- инструмент: посредством чего осуществляется действие
- экспериенцер: носитель чувств и восприятий
- стимул: источник восприятий
- источник: исходный пункт движения
- цель: конечный пункт движения

---

*C.J.Fillmore.* The Case for Case. Universals in Linguistic Theory. 1968.

*D.Jurafsky, J.Martin.* Speech and Language Processing. Chapter 20. 2019.

# Нотация BIOES (begin-inside-outside-end-single)

Для выделения групп слов используются метки с префиксами:

- B–Begin, I–Inside, O–outside — упрощённая BIO-нотация
- E–end, S–single

Пример задачи распознавания именованных сущностей:

| B-PER | I-PER | I-PER | I-PER | E-PER | OUT | OUT | S-LOC |
|---|---|---|---|---|---|---|---|
| Карл | Фридрих | Иероним | фон | Мюнхгаузен | родился | в | Боденвердере |

Пример задачи определения семантических ролей:

| B_ACT | I_ACT | I_ACT | O | B_NUM_PER | O | B_LOC | I_LOC |
|---|---|---|---|---|---|---|---|
| Book | a | table | for | 3 | in | Domino's | pizza |

# Пример инструмента разметки текста

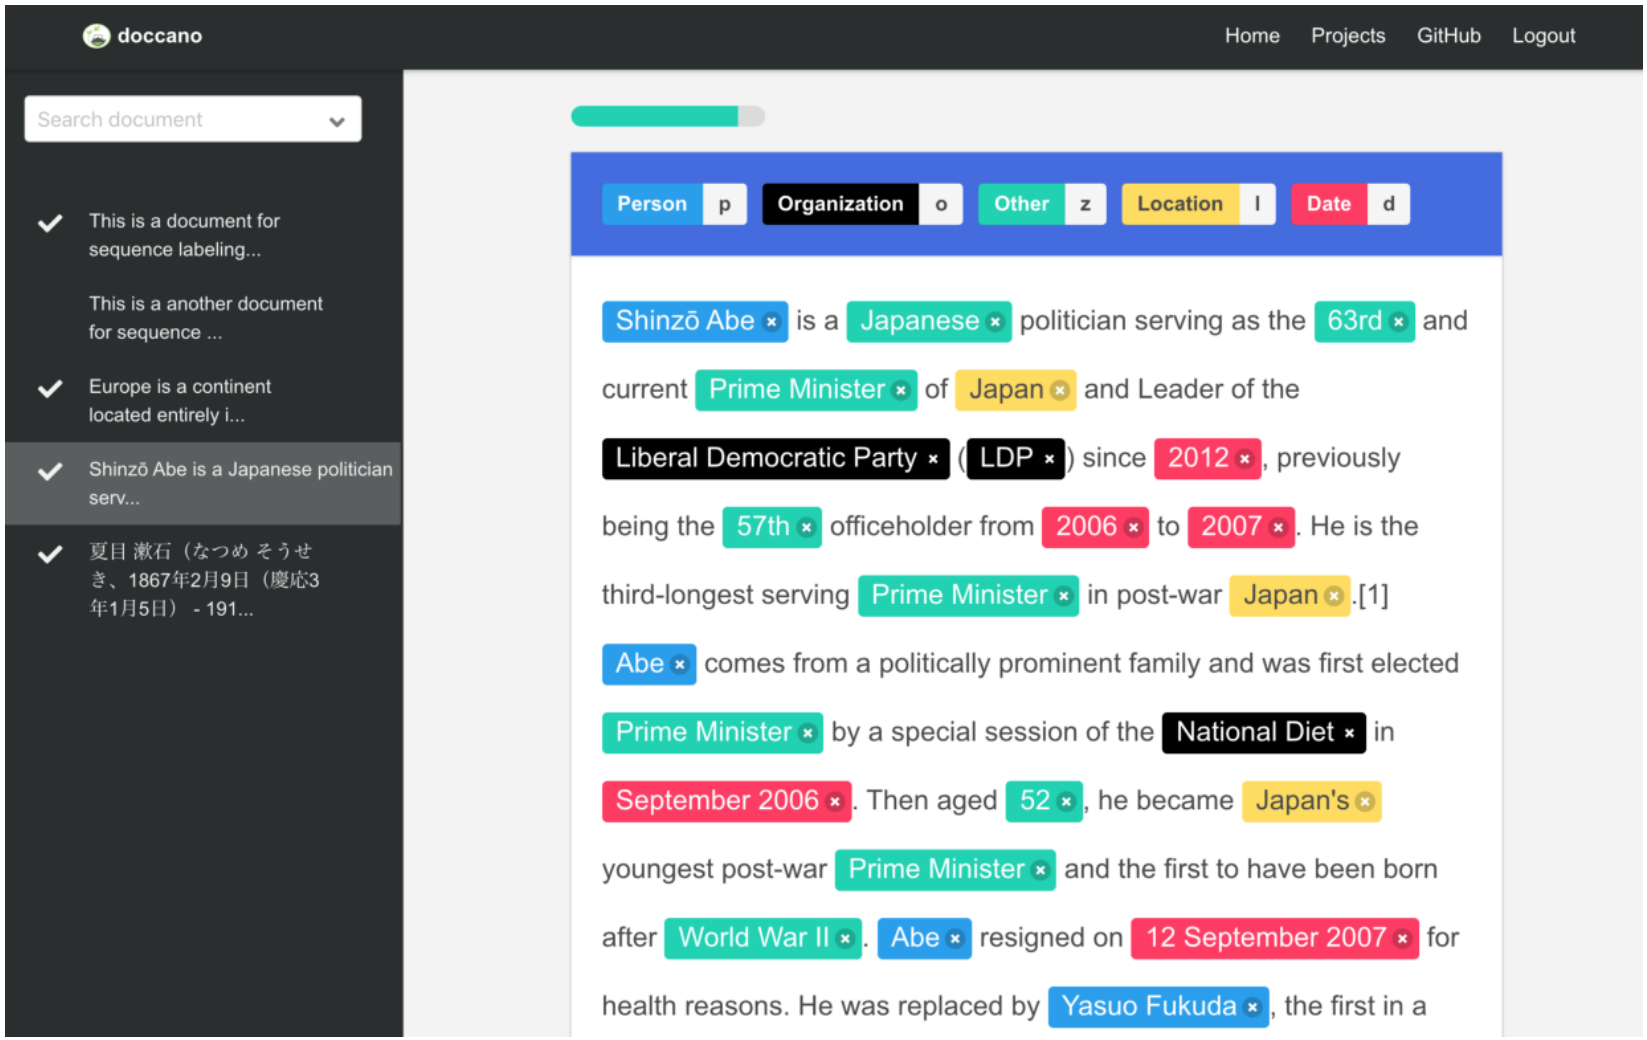


Text annotation for Human. https://doccano.herokuapp.com

# Линейная предсказательная модель разметки

Пусть $D$ — множество размеченных последовательностей $(x, y)$,
$x = (x_1, \ldots, x_\ell)$ — последовательность объектов из $X$,
$y = (y_1, \ldots, y_\ell)$ — последовательность меток из $Y$.

**Например,** данные $D$ — все предложения коллекции текстов;
в предложении $(x, y) \in D$ слову $x_i$ соответствует метка $y_i$.

**Линейная модель** с параметром $w \in \mathbb{R}^n$ оценивает целиком набор меток $y$ для последовательности $x$ (structured prediction):

$$\langle w, F(x, y)\rangle = \sum_{j=1}^{n} w_j F_j(x, y)$$

Признаки $F_j$ складываются из признаков отдельных объектов:

$$F_j(x, y) = \sum_{i=1}^{\ell} f_j(y_{i-1}, y_i, x, i), \quad j = 1, \ldots, n$$

# Замечания о формировании признаков $f_j$

$f_j(y', y, x, i)$ — это информация о последовательности $x$, полезная для предсказания метки $y_i = y$ в позиции $i$, когда в предыдущей позиции $(i-1)$ находится метка $y_{i-1} = y'$.

- $f_j(\bullet, i)$ может зависеть от всего $x$, не только от $x_i$
- $f_j(\bullet, i)$ не может зависеть от других меток, кроме $y_{i-1}$ (*марковское свойство*, упрощающее вывод, см. далее)
- часто используются бинарные $f_j$, но это не обязательно
- часто используются разреженные признаки
- число признаков $n$ может достигать десятков тысяч
- если $w_j = 0$, то признак $f_j$ не информативен
- последовательности $(x, y)$ могут иметь любые длины $\ell$, но размерность $F(x, y)$ фиксирована и равна $n$

# Примеры признаков $f_j(y_{i-1}, y_i, x, i)$ для POS-теггинга

Признаки могут выражать наши гипотезы, от чего зависит $y_i$:

- $y_i = \text{ADVERB}$ и слово $x_i$ оканчивается на «-ly»
  Если $w_j > 0$, то такие слова действительно часто оказываются наречиями
- $i = 1$ и $y_i = \text{VERB}$ и предложение оканчивается знаком «?»
  Если $w_j > 0$, то первое слово в вопросительных предложениях действительно часто оказывается глаголом
- $y_{i-1} = \text{ADJECTIVE}$ и $y_i = \text{NOUN}$
  Если $w_j > 0$, то существительные действительно часто следуют за прилагательным
- $y_i = \text{PREPOSITION}$ и $y_{i-1} = \text{PREPOSITION}$
  Если $w_j < 0$, то перед предлогом действительно редко находится другой предлог

# Построение вероятностной линейной модели разметки

Аналог многоклассовой логистической регрессии:

$$p(y|x;w) = \frac{1}{Z(x,w)} \exp\langle w, F(x,y)\rangle\,, \quad y \in Y^\ell$$

где $Z(x,w) = \sum_{y \in Y^\ell} \exp\langle w, F(x,y)\rangle$ — нормировочный множитель

**Принцип максимума правдоподобия:**

$$\sum_{(x,y)\in D} \ln p(y|x;w) \to \max_w$$

Оптимальная последовательность меток при известном $w$:

$$\hat{y} = \arg\max_{y \in Y^\ell} p(y|x;w)$$

Эффективное вычисление $\arg\max$ и $\sum$ по $Y^\ell$ возможно благодаря марковскому свойству признаков $f_j(y_{i-1}, y_i, x, i)$.

# Вычисление оптимальной разметки

Оптимальная последовательность меток при известном $w$:

$$\hat{y} = \arg\max_{y \in Y^\ell} \sum_{j=1}^{n} w_j F_j(x, y) = \arg\max_{y \in Y^\ell} \sum_{j=1}^{n} w_j \sum_{i=1}^{\ell} f_j(y_{i-1}, y_i, x, i) =$$

$$= \arg\max_{y \in Y^\ell} \sum_{i=1}^{\ell} \sum_{j=1}^{n} w_j f_j(y_{i-1}, y_i, x, i)$$

Вычислим $Y \times Y$-матрицы $G_i[y', y]$, $i = 1, \ldots, \ell$, $y', y \in Y$:

$$G_i[y', y] = \sum_{j=1}^{n} w_j f_j(y', y, x, i)$$

Определим $\ell \times Y$-матрицу $U[k, v]$, $k = 1, \ldots, \ell$, $v \in Y$:

$$U[k, v] = \max_{y_1 \ldots y_{k-1}} \left( \sum_{i=1}^{k-1} G_i[y_{i-1}, y_i] + G_k[y_{k-1}, v] \right)$$

# Алгоритм Витерби (динамическое программирование)

**Прямой ход:** рекуррентное вычисление матрицы $U$:

$$U[0, v] := 0;$$
$$U[k, v] := \max_{u \in Y} \big( U[k-1, u] + G_k[u, v] \big), \quad k = 1, \ldots, \ell, \ v \in Y.$$

**Обратный ход:** вычисление оптимальной разметки $\hat{y} \in Y^\ell$:

$$\hat{y}_\ell := \arg\max_{v \in Y} U[\ell, v];$$
$$\hat{y}_{k-1} := \arg\max_{u \in Y} \big( U[k-1, u] + G_k[u, \hat{y}_k] \big), \quad k = \ell, \ldots, 2.$$

Алгоритм Витерби находит оптимальное решение:

- прямой ход: $O(|Y|^2 \tilde{n} \ell)$, $\tilde{n}$ — число ненулевых признаков
- обратный ход: $O(|Y|^2 \ell)$

---

*Andrew Viterbi*. Error bounds for convolutional codes and an asymptotically optimum decoding algorithm. 1967.

# Алгоритм SG (Stochastic Gradient) Роббинса–Монро

Максимизация логарифма правдоподобия:

$$\sum_{(x,y)\in D} \ln p(y|x;w) \to \max_w$$

**Идея ускорения сходимости SG:** обновлять вектор весов $w$ после градиентного шага по каждому слагаемому

**Вход:** выборка $D$, темп обучения $h$;
**Выход:** вектор весов $w$;
инициализировать веса $w_j$, $j = 1,\ldots,n$;
**повторять**
  выбрать последовательность $(x, y)$ из $D$;
  сделать градиентный шаг: $w := w + h\nabla \ln p(y|x;w)$;
**пока** веса $w$ не сойдутся;

---

*Robbins, H., Monro S.* A stochastic approximation method // Annals of Mathematical Statistics, 1951, 22 (3), p. 400–407.

# Вычисление градиента

Градиент одного слагаемого log-правдоподобия по $w$:

$$\frac{\partial}{\partial w_j} \ln p(y|x;w) = F_j(x,y) - \frac{\partial}{\partial w_j} \ln Z(x,w) =$$

$$= F_j(x,y) - \frac{1}{Z(x,w)} \frac{\partial}{\partial w_j} Z(x,w);$$

$$\frac{\partial}{\partial w_j} Z(x,w) = \frac{\partial}{\partial w_j} \sum_{y \in Y^\ell} \exp \sum_{k=1}^{n} w_k F_k(x,y) =$$

$$= \sum_{y \in Y^\ell} F_j(x,y) \exp \sum_{k=1}^{n} w_k F_k(x,y);$$

$$\frac{\partial}{\partial w_j} \ln p(y|x;w) = F_j(x,y) - \sum_{u \in Y^\ell} F_j(x,u) p(u|x;w).$$

# Упрощение вычислений благодаря марковскому свойству

Подставим в градиент выражение $F_j$ через $f_j$:

$$\sum_{u \in Y^\ell} p(u|x;w) F_j(x,u) = \sum_{u \in Y^\ell} p(u|x;w) \sum_{i=1}^{\ell} f_j(u_{i-1}, u_i, x, i) =$$

$$= \sum_{i=1}^{\ell} \sum_{u_{i-1} \in Y} \sum_{u_i \in Y} p(u_{i-1}, u_i|x;w) f_j(u_{i-1}, u_i, x, i).$$

Осталось найти способ быстрого вычисления $p(u_{i-1}, u_i|x;w)$.

Вспомним выражение $Z(x,w) = \sum_{y \in Y^\ell} \underbrace{\exp \sum_{i=1}^{\ell} G_i[y_{i-1}, y_i]}_{N(y)}$.

Назовём $N(y)$ *ненормированной вероятностью* $y = (y_1, \ldots, y_\ell)$.

# Два семейства векторов: вперёд и назад

Определим векторы ненормированных вероятностей для начальных $(y_1, \ldots, y_k)$ и конечных $(y_k, \ldots, y_\ell)$ фрагментов.

Начальные фрагменты, завершающиеся меткой $v$ в позиции $k$:

$$\alpha_k[v] = \sum_{y_1 \cdots y_{k-1}} \exp\Big(\sum_{i=1}^{k-1} G_i[y_{i-1}, y_i] + G_k[y_{k-1}, v]\Big), \qquad v \in Y$$

Конечные фрагменты, начинающиеся меткой $u$ в позиции $k$:

$$\beta_k[u] = \sum_{y_{k+1} \cdots y_\ell} \exp\Big(G_{k+1}[u, y_{k+1}] + \sum_{i=k+2}^{\ell} G_i[y_{i-1}, y_i]\Big), \quad u \in Y$$

Для них существуют эффективные рекуррентные формулы (аналогичные алгоритму Витерби, только $\sum$ вместо max)

# Рекуррентные формулы для вперёд-векторов и назад-векторов

**Вперёд-векторы** (forward vectors):

$$\alpha_k[v] = \sum_{u \in Y} \alpha_{k-1}[u] \exp G_k[u, v];$$
$$\alpha_0[v] = [v = \text{start}]$$

где $y_0 = \text{start}$ — выделенная метка начала последовательности.

**Назад-векторы** (backward vectors):

$$\beta_k[u] = \sum_{v \in Y} \beta_{k+1}[v] \exp G_{k+1}[u, v];$$
$$\beta_{\ell+1}[u] = [u = \text{stop}]$$

где $y_{\ell+1} = \text{stop}$ — выделенная метка конца последовательности.

# Полезные свойства вперёд-назад-векторов

Через $\alpha_k[v]$, $\beta_k[u]$ выражаются различные вероятности:

- $Z(x,w) = \sum_{v \in Y} \alpha_\ell[v]$
- $Z(x,w) = \sum_{u \in Y} \alpha_k[u]\,\beta_k[u]$ для любого $k = 1, \ldots, \ell$
- $p(y_i = u | x; w) = \dfrac{\alpha_i[u]\,\beta_i[u]}{Z(x,w)}$
- $p(y_{i-1} = u, y_i = v | x; w) = \dfrac{\alpha_{i-1}[u]\,\beta_i[v]\,\exp G_i[u,v]}{Z(x,w)}$

Отсюда получается выражение для градиента:

$$\frac{\partial \ln p(y|x;w)}{\partial w_j} = F_j(x,y) - \sum_{i=1}^{\ell} \sum_{y_{i-1} \in Y} \sum_{y_i \in Y} p(y_{i-1}, y_i | x; w) f_j(y_{i-1}, y_i, x, i)$$

# Собираем всё воедино: основной цикл алгоритма SG

**повторять**

выбрать последовательность $(x, y)$ из $D$;

$G_i[u, v] := \sum_{j=1}^{n} w_j f_j(u, v, x, i)$ для $i = 1..\ell,\ u, v \in Y$;

$\alpha_i[v] := \sum_{u \in Y} \alpha_{i-1}[u] \exp G_i[u, v]$ для $i = 1..\ell,\ v \in Y$;

$\beta_i[u] := \sum_{v \in Y} \beta_{i+1}[v] \exp G_{i+1}[u, v]$ для $i = \ell..1,\ u \in Y$;

$Z := \sum_{v \in Y} \alpha_\ell[v]$;

$p_i[u, v] := \frac{1}{Z} \alpha_{i-1}[u]\, \beta_i[v] \exp G_i[u, v]$ для $i = 1..\ell,\ u, v \in Y$;

$\nabla_j := F_j(x, y) - \sum_{i=1}^{\ell} \sum_{u,v \in Y} p_i[u, v] f_j(u, v, x, i)$ для $j = 1..n$;

градиентный шаг: $w := w(1 - \tau h) + h\nabla$;

**пока** веса $w$ не сойдутся;

# Максимизация регуляризованного правдоподобия

$L_2$-регуляризация для уменьшения переобучения:

$$\sum_{(x,y)\in D} \ln p(y|x;w) + \tau \sum_{j=1}^{n} w_j^2 \to \max_w$$

$L_1$-регуляризация с отбором признаков:

$$\sum_{(x,y)\in D} \ln p(y|x;w) + \gamma \sum_{j=1}^{n} |w_j| \to \max_w$$

ElasticNet с менее агрессивным отбором признаков:

$$\sum_{(x,y)\in D} \ln p(y|x;w) + \gamma \sum_{j=1}^{n} |w_j| + \tau \sum_{j=1}^{n} w_j^2 \to \max_w$$

# CRF — обобщение скрытых марковских моделей HMM

HMM (Hidden Markov Model) моделирует совместную плотность

$$p(x,y) = \prod_{i=1}^{\ell} p(x_i|y_i)\,p(y_i|y_{i-1}) = \exp \sum_{i=1}^{\ell} \underbrace{\ln p(x_i|y_i)}_{w_{x_i y_i}} + \underbrace{\ln p(y_i|y_{i-1})}_{w_{y_i y_{i-1}}} =$$

$$= \exp\Bigg( \sum_{i=1}^{\ell} \sum_{x\in X} \sum_{y\in Y} w_{xy} \underbrace{[y_i = y]\,[x_i = x]}_{f_{xy}} +$$

$$+ \sum_{y'\in Y} \sum_{y\in Y} w_{y'y} \underbrace{[y_{i-1} = y']\,[y_i = y]}_{f_{y'y}} \Bigg) =$$

$$= \frac{1}{Z} \exp\Bigg( \sum_{i=1}^{\ell} \sum_{j=1}^{n} w_j f_j(y_{i-1}, y_i, x, i) \Bigg)$$

# CRF — обобщение скрытых марковских моделей HMM

HMM — генеративная модель совместной плотности

$$p(x,y) = \frac{1}{Z}\exp\left(\sum_{i=1}^{\ell}\sum_{j=1}^{n} w_j f_j(y_{i-1}, y_i, x, i)\right)$$

CRF — дискриминативная модель $p(y|x)$, обобщающая HMM:

- $y_i$ зависит от всего $x$, а не только от $x_i$
- произвольные $f_j$, а не только индикаторы (и тогда $Z \neq 1$)
- произвольные $n$, а не $|X| \cdot |Y| + |Y|^2$
- произвольное множество $X$, а не только конечное
- для вывода $\hat{y}$ в HMM также используется Витерби
- для обучения в HMM чаще используется EM, чем SG

# CRF с частичным обучением

Пусть наряду с $D$ имеются неразмеченные данные $U = \{u\}$, $u = (u_1, \ldots, u_\ell)$ — последовательность объектов $u_i \in X$

Энтропийный регуляризатор:

$$\sum_{(x,y)\in D} \ln p(y|x;w) + \tau \sum_{u\in U} \sum_{y\in Y^\ell} p(y|u;w) \ln p(y|u;w) \to \max_w$$

Минимизация энтропии уменьшает неопределённость, распределения $p(y|u;w)$ становятся сконцентрированными, менее похожими на равномерное распределение, повышается уверенность классификации неразмеченных $u$.

Вычисление градиента динамическим программированием так же эффективно, как для размеченных данных, $O(|Y|^2 \tilde{n}\ell)$.

---

*G.Mann, A.McCallum.* Efficient computation of entropy gradient for semi-supervised Conditional Random Fields. 2007.

# CRF — дискриминативная модель

CRF обобщает логистическую регрессию и скрытые марковские модели (Hidden Markov Model, HMM).

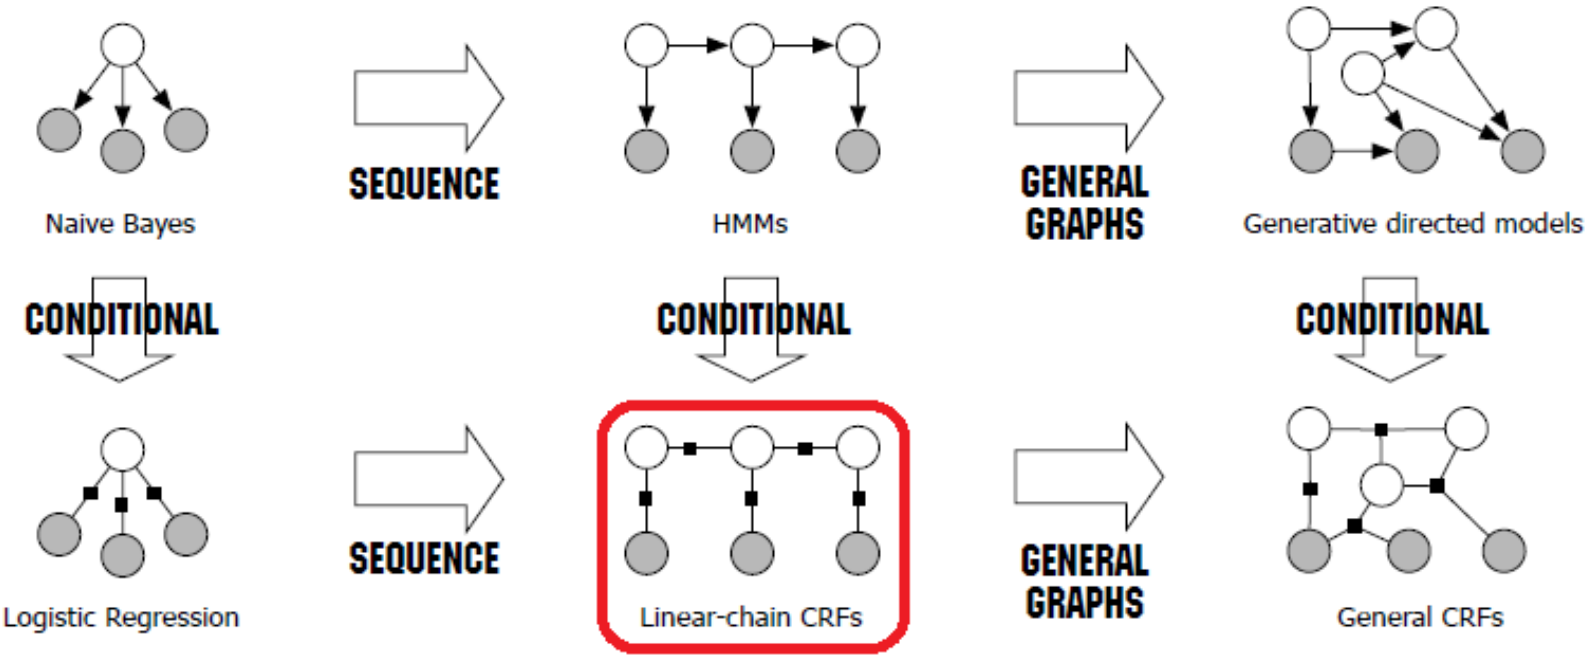


Генеративные модели: $p(x, y; w)$

Дискриминативные модели: $p(y|x; w)$, не моделируется $p(x)$

---

*C.Sutton, A.McCallum.* An introduction to Conditional Random Fields. 2011.

# Ещё несколько обобщений CRF

- HCRF: Hidden-state CRF

*Quattoni, Wang, Morency, Collins, Darrell.* Hidden conditional random fields. 2007.

- LDCRF: Latent-Dynamic CRF

*Sung, Jurafsky.* Hidden Conditional Random Fields for phone recognition. 2009.

- CCRF: Continuous CRF

*Qin, Liu.* Global ranking using continuous conditional random fields. 2008.

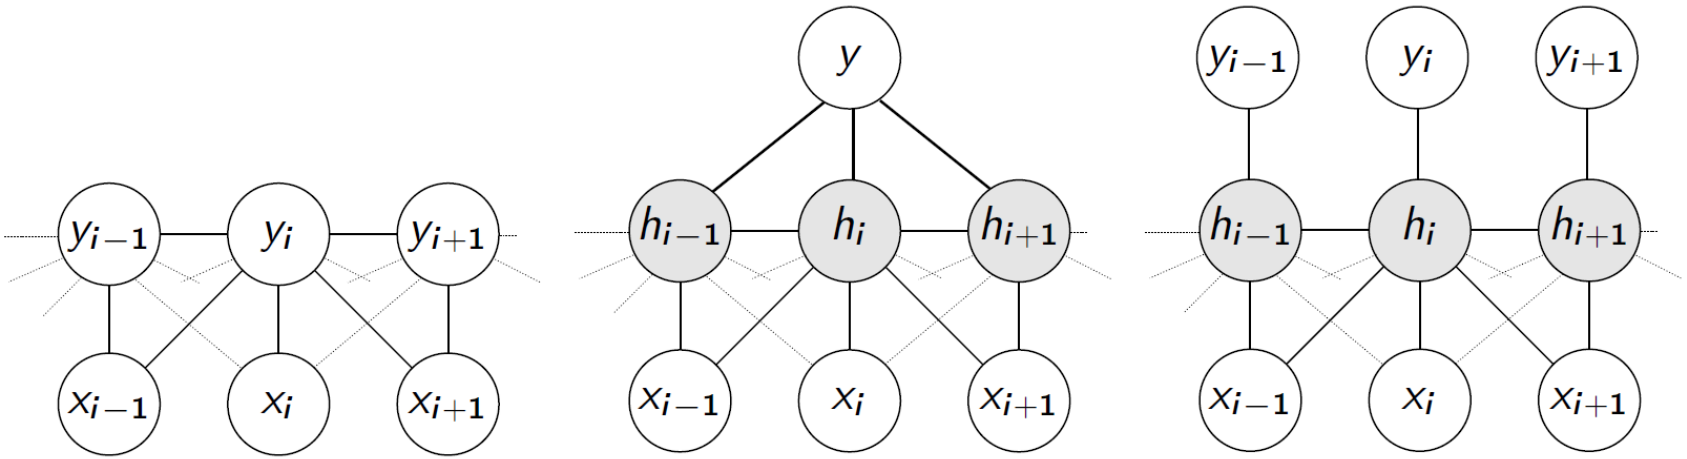

# Литература


*Charles Elkan. (2012).*
*Log-linear models and Conditional Random Fields.*
— коротко и понятно объясняются все детали в формулах, 20 стр.

*Charles Sutton, Andrew McCallum. (2011).*
An introduction to Conditional Random Fields.
— прекрасный канонический обзор, но слишком детальный, 120 стр.

*John Lafferty, Andrew McCallum, Fernando Pereira. (2001).*
Conditional Random Fields: probabilistic models for segmenting and labeling sequence data.
— первая статья про CRF.